

教育案例全链路实录·总述


一、本文档是什么

本文档是研究方案生成管线(plan_gen)在教育课题上的一次端到端运行实录,相当于一次完整集成测试的执行轨迹:输入一篇综述,依次经过每个处理站,最终输出一份申报书级研究方案。各站的真实运行产物均有留档;唯一例外是第 0 站(见下文篇章表)——当时在终端输入的检索 query 逐字原文未存档,后文按模板与产物结构复原,详见该篇。

每一站的记录采用同一体例:先说明该站的职责与规则(相当于接口文档),再摘录真实运行产物的原文(相当于日志),最后解析"输入如何变成输出"。目的有二:其一,使评审者能沿证据链追溯任意结论的来源;其二,记录质量保障机制(自动审查、代码断言、人工确认)在真实运行中的触发实例。

二、案例与管线概况

本案例的选题来源是李龙娟发表的综述《中外人工智能赋能个性化学习研究的可视化比较分析及启示》(下称"种子文献")。管线上游由检索综述工具 OpenProvHop 围绕同一主题另行生成一份领域方法综述报告(27 个来源,约 4500 词,下称"综述报告"——注意它与种子文献是两份不同的文档),随后综述报告进入本仓库的各处理站。整体流程如下图(与 GitHub 仓库 README 中的流程图一致):



本实录聚焦图中第 5 步(提炼研究目标)与第 6 步(展开成研究方案)的全部内部环节;第 4、7、8 步(写前两节、翻译、拼装 PDF)不展开;另设"第 0 站"一篇,补记上游第 1~3 步是如何起步的。全部内容按运行顺序拆为八篇:

篇章	对应环节	职责
第 0 站	上游第 1~3 步	设计检索 query,使报告结构服务于下游各站
A 步	第 5 步·拆解	把综述按方法转录为九张"方法单元卡"(units.json)
B 步	第 5 步·找空白	横向对照单元卡,挖出卡与卡之间的研究空白
去重+C 步	第 5 步·出候选	合并重复空白;把空白转写为候选研究目标
反思站	第 5 步·审查	逐条打分判决候选,拦截数值语义问题
D 步与选定	第 5 步·成稿	扩写申报书正文;锦标赛排序;人工选定目标
design 上	第 6 步·定规矩	领域画像;钉子与维度分类(两处人工确认)
design 下	第 6 步·出方案	代码推实验骨架;扩写四节;评审与安检

三、术语速查(按程序员的直觉解释)

术语	含义
管线	即 pipeline:多个处理站串行,上一站的输出是下一站的输入
站与步	管线阶段的代称:提炼研究目标的工具 goal_gen 内部按步骤编号——A(拆卡)→B(挖空白)→去重→C(转候选)→反思→D(扩写成文);"站"指更大的阶段,如反思站、design 站(设计实验方案)
U·方法单元卡	units.json 里的一条结构化记录,一种方法一条,类似数据表的一行,字段含方法名/国内外/数据/指标/局限;正文中的 U1~U9 即这九张卡的编号
G·研究空白	gap:综述里没人解决的问题,由模型横向对照单元卡挖出,是候选目标的来源;正文中的 G1~G3 即本案例三条空白的编号
钉子	锁死的全局控制变量(研究任务/实验载体/主数据),锁定后下游任何一站不得更改,防止长文生成时"漂移"
黄灯	人工确认断点:程序暂停,把关键决定打印在终端,人确认或改掉后才继续
负对照	故意构造的坏样本测试:埋入已知缺陷,验证质量闸能否拦住,同时确认好样本不被误杀(类似单元测试里的反例用例)
tripwire	纯代码的确定性检查(正则/计数/查表),类似断言:同输入必同输出,零成本零随机
锦标赛	对完整成稿多维打分并排序,只排名不改稿,最终选择权在人
领域画像	生成正文前先让模型推导"该领域论文的话术与验证手段"并经人确认,防止提示词示例把别的领域的行话带进来

四、全程数据一览

环节	输入	输出	质量动作
第 0 站	选题主题	综述报告(27 来源)	开放问题章留作对照
A 步	综述正文	9 张方法单元卡	忠实转录,推断挂标签
B 步	9 张卡	3 条空白(G1/G2/G3)	证据可追责,宁缺毋滥
去重	3 条空白	3 条(无合并)	负对照实验验证
C 步	3 条空白	3 个候选目标	现状数值须注明出处
反思站	3 个候选	0 淘汰,1 标记(G2)	数值语义审查生效
D 步与选定	3 个候选	3 段正文,选定目标一	锦标赛 14/11/9 分
design 站	目标一+4 张卡	四节研究方案	评审 4 条+安检 4 道

表中的三条空白在后文以编号加简称指代:G1(轻量/公平/隐私无人兼顾)、G2(低资源场景未验证)、G3(隐私技术未迁移)。另有两个数字值得先行说明:

- 综述报告的"开放问题"一章被刻意排除在管线输入之外,留作标准答案;事后对照,管线自主挖出的三条空白命中了该章点名方向的四分之三(详见第 0 站)。
- 候选二(源自空白 G2)的基线数值"87%"被反思站标记:数字本身是真的,但它在候选目标里被赋予的含义已不同于综述原文中的含义(即"语义偏移")。该标记随文稿一路可见,直至人工处理(详见 C 步与反思站)。

五、质量保障的通用模式

全链凡包含 AI 起草环节的处理站,都遵循同一套四层模式:AI 起草 → AI 按标准自查修改 → 代码做确定性检查(tripwire) → 人工按复核清单确认。三点设计立场贯穿始终:

- 语义判断与机械核算分离:判断类工作交给模型;取并集、查真值表、清点配置组数这类确定性工作交给代码,二者不越界。
- 关键决定设黄灯:领域画像与实验钉子这类决定一旦定错,下游会整体偏离(即"漂移":后续生成内容偏离此前定下的设定),因此程序在这些决定处必须暂停,等人确认后再继续;文中记录了一次真实的钉子被带偏、由人工拦下的事故(见 design 上篇)。
- 负对照验证:去重、反思等质量闸均以人工构造的缺陷样本验证过"能拦住什么、拦不住什么",能力边界如实记录,不夸大覆盖面。

六、阅读指引与体例

后续八篇按管线顺序排列,每篇均可独立阅读。体例约定:

- 标注"照录"的缩进块为运行产物原文,一字未改;
- U 编号指方法单元卡(U1~U9,与方法名的对照表见 A 步篇末);G 编号指研究空白,本案例共三条——G1(轻量/公平/隐私无人兼顾)、G2(低资源场景未验证)、G3(隐私技术未迁移);
- "□"为反思站的标记判决,表示该内容待人工确认;
- 除第 0 站以"产物与交接"一节收束外,各篇末尾均有总表汇总该站的输入、输出与去向。

教育案例全链路实录 · 第 0 站:向 OpenProvHop 提出研究问题

本站是整条管线的起点。管线的第一个动作不是编写代码,而是提出一个问题:OpenProvHop 是忠实执行指令的检索综述工具,提问的内容与格式直接决定报告的结构,进而决定下游每一站是否有可用的原材料。因此 query 的设计是全链的地基:其中每一句都对应下游某一站的输入需求(逐句对应关系见第三节)。

一、主题与选题依据

主题:中外人工智能赋能个性化学习的方法综述。

选题的起点文献为本文件夹内李龙娟《中外人工智能赋能个性化学习研究的可视化比较分析及启示》。以真实发表的综述作为选题依据有一个好处:它自带"标准答案"——作者在文末点名了尚未解决的开放方向。事后把管线自行挖掘的研究空白与这些方向逐条对照,就能算出命中比例(下称"空白复现率"),"生成质量"由此从主观感受变成可核对的指标。"中外对照"的取向也决定了下游 A 步(管线的拆卡步骤,负责把报告逐节转录成方法单元卡,详见 A 步篇)需要抽取 origin(国内/国外)字段。

二、query 全文

query 由固定模板填入主题而成。需要说明的是,当时终端输入的逐字原文未存档,下面展示的是把同一主题填回模板得到的复原版。复原版之所以可信,是因为可以拿实际产物验证:模板的每条要求都能在 report.md 中找到对应结构。例如,query 要求对每个方法覆盖 (1)~(4) 四项内容,report.md 每一节恰好按这四项各写一段;query 要求"总结开放问题",report.md 结尾恰好有开放问题一章。query 原文虽是复原版,但其逐句均可在产物上验证。

```
Write a detailed literature review of existing methods for AI-enabled
personalized learning in China and abroad.
Survey PRIOR WORK ONLY — do NOT propose new methods or design experiments.
For EACH method or approach, cover:
(1) what it does and its core idea;
(2) the datasets/benchmarks and settings it was evaluated on;
(3) its reported quantitative results (accuracy, error, runtime, etc.
    — include the actual numbers);
(4) its limitations or weaknesses.
Also summarize the open problems and remaining gaps in the field.
Organize the review method by method.
```

运行方式:执行 python -m src.run,选择 report 模式(产出完整综述报告的模式),检索宽度参数 breadth 取 6~8。

实际产出:2026-07-16,27 个来源,约 4500 词。

三、逐句设计意图(每句服务于下游的某一站)

query 里这句	服务于下游哪一站
"existing methods, PRIOR WORK ONLY"	约束产出为综述而非提案,A 步才有现成方法可抽取
"for EACH method ... core idea / datasets / results"	对应 A 步方法单元卡的字段结构(方法/数据/指标逐字段有材料)
"include the actual numbers"	服务 C 步定量增量(现状基线须为真实数字)

query 里这句	服务于下游哪一站
"its limitations or weaknesses"	B 步挖空白的关键前提——检索工具默认侧重成果,不主动询问局限,报告便只述成绩,B 步将无空白可挖
"open problems and remaining gaps"	为 B 步提供额外线索;该章同时留作"标准答案"对照(不输入管线)
"organize method by method"	使 A 步可逐节拆分,一节一张卡

四、“开放问题”一章的对照设计

报告的“开放问题”一章刻意不输入管线:正文进入管线,该章留存作为标准答案,用于事后检验管线自行挖掘的空白能否命中该章点名的方向。本次教育课题运行中,该章点名的开放方向有四分之三被管线挖出的空白命中(即第一节所说的空白复现率)。

五、产物与交接

report.md(本文件夹)为经 OpenProvHop 反思环节(工具自动对照证据逐句核查并修订初稿的步骤)修订后的完整报告,含开放问题一章;openprovhop_review.txt 为人工截取的正文部分(开放问题一章之前),是管线的实际输入。

教育案例全链路实录·A 步:从反思后的报告抽取方法单元

A 步的职责,是把经上游反思环节(OpenProvHop 内置的自动复查修订步骤,负责核验引用真伪)处理后的综述报告(openprovhop_review.txt)按方法逐条转录为结构化的"方法单元卡"(units.json 里的一条条记录,一种方法一条,类似数据表的一行)。工作原则有三:忠实转录、拒绝编造、推断内容必须标注"(推断)"。本步转录由大模型执行,采样温度设为 0.2(低温度,输出稳定、少自由发挥)。引用真伪上游已核验,A 步只负责转录,不负责查证。以下用三段报告原文对照展示抽取过程。

一、对照例一:报告 2.2 节(机器学习方法) → U2 卡

【报告原文(照录)】

```
**Core Ideas & Variants:**
- *Random Forest / SVM:* Predictive modeling for identifying 'at-risk'
  students or recommending resources...
- *Neural Networks (NN):* Deep learning architectures processing
  multimodal data...
- *Gradient Boosting Machines (GBM):* Ensemble methods for competency
  mapping and weight optimization...
**Datasets/Evaluation:**
- **Junaidi et al. (2025):** Competency-based framework evaluated on
  22,304 students across 46 courses mapped to 90 competencies
  (Higher Ed Indonesia)
- Kaggle's "AI-Powered Personalized Learning Dataset" (2025)
**Quantitative Results:**
- **GBM (Competency Selection):**  $R^2=0.9997$ ,  $MSE=0.0221$  (Junaidi et al.)
- Random Forest achieved 93% accuracy in career recommendations
**Limitations:**
- **Bias Amplification:** Spectral radius  $\rho > 1$  in feedback loops worsens
  demographic disparities
- **Computational Complexity:** Deep NNs require GPU clusters unavailable
  to 83% of rural Chinese schools (Li & Mohammad, 2025)
```

【本段抽取结果】

- work 字段为"机器学习方法":RF、NN、GBM 三个小节合并为一张卡(规则:同属一类方法的多个算法合并为一张卡,不拆分为多条)。
- origin 字段判为"国外",依据是原文含 Indonesia 线索;按规则,只有原文提供国别线索时才可判定,否则记"未知"。
- data_scene 字段收录 Junaidi 研究(22,304 名学生、46 门课程、90 项能力)与 Kaggle 数据集:数字原样转录。该字段收录的数据集构成候选范围,后续 design 站(实验方案设计环节)挑选主实验数据集时只允许从中选取。
- metrics 字段收录 5 项指标(GBM $R^2=0.9997$ 、 $MSE=0.0221$ 、随机森林 93% 等);value 逐字抄录。C 步(把空白转写成研究目标的环节)引用基线数值时,只允许取自这份指标列表。
- limitation 字段收录两条:偏见放大(连"谱半径 $\rho > 1$ "这句原文中未加定义、表述不清的话也原样照抄,不代为润色——忠实转录优先于文字修正);深度网络需 GPU 集群、83% 中国农村学校不可得。这条 83% 的数据自此被记入单元卡,后续撰写研究目标一时被直接引用进正文。

- 卡上另有一条"(推断)可能在高噪声数据中过拟合":原文没有此句,推断是唯一允许的加工方式,且必须挂"(推断)"标签。

二、对照例二:报告 2.8 节(AI 辅助评估工具) → U8 卡

【报告原文(照录)】

****Core Idea:****

Automated grading (AES), predictive analytics for dropout risk, and plagiarism detection via NLP/ML.

****Datasets/Evaluation:****

- Zhao's (2024) review: 81 studies of STEM assessment tools
- AI-Powered Personalized Learning Dataset (Kaggle, 2025)

****Quantitative Results:****

- Grading time reduced from 10min to 45sec per essay (AES systems)
- 89% accuracy in early dropout prediction (3+ weeks pre-incident)

****Limitations:****

- Algorithmic bias: Black students flagged as 'at-risk' 2.3× more than white peers despite similar grades (Bird et al., 2024)
- Ineffectiveness against AI-facilitated cheating

【本段抽取结果】

- work 字段为"AI辅助评估工具";solves 字段为自动评分、辍学风险预测、抄袭检测。
- origin 字段判为"未知":原文未提供国别线索,不作猜测(与例一形成对照)。
- data_scene 字段收录 Zhao 的 81 项研究与 Kaggle 数据集。
- metrics 字段收录 2 项:评分时间由 10 分钟降至 45 秒;辍学预测准确率 89%(测量条件"事件前 3+ 周"也一并录入 condition 字段)。
- limitation 字段收录:黑人学生被误标为"风险"的比例是白人的 2.3 倍(成绩相似)。该 2.3 倍是本案例最重要的数字。B 步(横向对照挖空白的环节)据此发现公平性空白;C 步把它用作描述现状的基线数值;到 design 站时,它被限定为只在问题背景部分引用,不再作其他用途。

三、对照例三:报告 2.9 节(隐私增强技术) → U9 卡

【报告原文(照录)】

****Core Idea:****

Implementing tokenization, homomorphic encryption, and federated learning to secure sensitive learner data in AI pipelines.

****Datasets/Evaluation:****

- TrustCloud's ethical AI framework (2025): Differential privacy in LMS

****Quantitative Results:****

- ≥99.5% clean traffic SLI via online tokenization gateways
- Homomorphic encryption maintained <6% performance overhead in training

****Limitations:****

- Federated learning bottlenecks: 3.7× latency spikes on low-bandwidth networks
- Regulatory fragmentation: GDPR ≠ China's PIPL compliance requirements

【本段抽取结果】

- work 字段为"隐私增强技术";solves 字段为令牌化、同态加密、联邦学习保护学习者数据。

- metrics 字段收录 2 项:清洁流量 SLI $\geq 99.5\%$;同态加密开销 $< 6\%$ 。SLI 这类含义不明的缩写同样如实抄录——是否采用是下游的决定,后续 overview 站的规则明确禁用了该缩写。
- limitation 字段收录:联邦学习在低带宽网络延迟飙升 3.7 倍;GDPR 与 PIPL 的合规差异。其中 3.7 倍后来成为研究目标三的依据(该目标针对"其他领域的轻量隐私技术未迁移到教育"这一空白);"联邦学习存在瓶颈"这条局限,则被 design 站的一条规则引作依据——该规则规定:不能仅凭采用联邦学习就宣称保护了隐私。

四、最终产物:九张方法单元卡(units.json 总表)

id	方法	国内外	定量指标	局限要点(节选)
U1	基于规则的系统	国外	2 项	规则手工编写,扩展性差
U2	机器学习方法	国外	5 项	偏见放大;深度网络需 GPU 集群
U3	NLP 与大型语言模型	国内	3 项	提示注入 31%;幻觉率 15-20%
U4	智能辅导系统	未知	2 项	课件开发 22 万美元/模块
U5	协同过滤与推荐	未知	2 项	冷启动 RMSE 飙升 42%
U6	强化学习	国外	2 项	奖励设计风险;需 PB 级数据
U7	生成式 AI(超越LLM)	未知	2 项	GAN 模式崩溃;伦理争议
U8	AI 辅助评估工具	未知	2 项	误标偏见 2.3 倍;防不了 AI 代写
U9	隐私增强技术	未知	2 项	低带宽延迟 3.7 倍;法规碎片化

抽取完成时,程序把综述全文与配置开关的 md5 存盘作为缓存指纹,保证同一份综述只抽取一次。后续的 overview(申报书前两节)与 goal(研究目标)两条产出线,共用这同一套方法单元卡。

教育案例全链路实录·B步:横向对照九张卡,挖出研究空白

B步的本质可以概括为一句话:研究空白不写在任何一张卡上,而藏在卡与卡的关系之中。A步是纵向的(一节原文对应一张卡,忠实转录),B步是横向的(九张卡并列对照,寻找卡与卡之间的张力)。以本轮挖出的第一条空白G1为例。四张卡各自记录了一条局限:U2(机器学习方法)称深度网络需GPU集群;U6(强化学习)称需要PB级数据;U8(AI辅助评估工具)称黑人学生被误标为"风险"的比例是白人的2.3倍;U9(隐私增强技术)称联邦学习在低带宽网络下延迟飙升3.7倍(均见下文原料节选)。每张卡单独看只是该方法自身的局限;四张卡放在一起,才浮现出"没有方法同时解决轻量、公平、隐私三件事"这一判断。该判断在综述中从未出现,是对照的产物。

本步的生成方式是发散式的:鼓励模型大胆联想、尽量多提候选空白。但发散同时受两条纪律约束:其一是可追溯——每条空白必须列明involved_units(涉及单元)与tension(张力,即描述卡与卡之间矛盾的一段文字),依据能一路查回真实的卡;其二是宁缺毋滥——条数不设上限,确有几条就给几条,不得为凑数而拆分或换词重述,确无空白则宁可少给。

本步具体设定:模型采样温度0.8(全链各步中最高,因为本步靠发散联想出活);以事先给定的一句话研究需求作为方向指引——本案例中即优先贴合"低资源教育场景+轻量化/公平/隐私";空白类型分五类并要求多样——能力缺口、数据场景缺口、假设失效、结论矛盾、迁移缺口。本轮实际挖出3条,后文以编号加简称指代:G1(轻量/公平/隐私无人兼顾)、G2(低资源场景未验证)、G3(隐私技术未迁移)。

一、对照例一:四张卡的局限交叉→G1(能力缺口)

【原料:四张卡的limitation(节选)】

U2 机器学习方法 深度神经网络需要 GPU 集群,83% 中国农村学校无法提供;
偏见放大(反馈循环加剧人口统计差异)
U6 强化学习 高方差训练:需要 PB 级数据
U8 AI辅助评估工具 黑人学生被误标为'风险'的比例是白人的 2.3 倍(成绩相似)
U9 隐私增强技术 联邦学习在低带宽网络延迟飙升 3.7 倍

【挖出的G1(照录gaps.json)】

类型:能力缺口
summary:没有任何方法在低资源教育场景下同时实现轻量化部署、
公平性保障和隐私保护。
involved_units:U2、U6、U8、U9
tension:U2 和 U6 因计算复杂性(需 GPU 集群或 PB 级数据)无法在 83% 中国
农村学校等低资源环境轻量化部署;U8 和 U2 存在算法偏见(人口统计
差异放大),损害公平性;U9 的隐私技术在低带宽网络延迟飙升,
与轻量化冲突,且无单元整合三者。

【对照分析】

单独审视任何一张卡,所见都只是该方法自身的局限;四张卡并列后结构才显现:轻量化缺口(U2 机器学习与 U6 强化学习均受算力制约)、公平缺口(U8 评估工具与 U2 机器学习均存在偏见)、隐私与轻量的冲突(U9 隐私增强技术),而"没有方法同时解决三者"这一判断不在任何单张卡上,只存在于卡与卡的关系里。这正是横向对照的价值所在。(G1 后来被选定为研究目标一,并一路保留、写入了最终研究方案。)

二、对照例二:两张卡的场景短板→G2(数据场景缺口)

【原料】

U3 NLP与大型语言模型 低资源语言环境中表现不佳(另有提示注入 31%、幻觉率 15-20% 等)
U5 协同过滤与推荐 冷启动问题:新用户/资源 RMSE 飙升 42%

【挖出的 G2(照录)】

类型:数据场景缺口
summary:现有方法主要在结构化或高资源数据环境验证,缺乏在低资源、多语言或稀疏数据场景下的全面评估与优化。
involved_units:U3、U5

【对照分析】

两张卡的短板指向同一件事的两面:现有方法的验证环境资源充裕、数据充足,一旦转入低资源场景(方言多样、数据稀疏)即告失灵。前文"空白分五类"的分类法在此派上用场——这不是"某种能力无人做到"(能力缺口),而是"各方法只在某类数据上验证过"(场景缺口)。每条空白会在后续 C 步被改写成一条研究目标;分类不同,改写出的目标形态也随之不同。

三、对照例三:单卡局限与领域外知识结合 → G3(迁移缺口)

【原料】

U9 隐私增强技术 同态加密高计算开销;联邦学习低带宽延迟飙升 3.7 倍

【挖出的 G3(照录)】

类型:迁移缺口
summary:其他领域成熟的轻量化隐私技术(如边缘计算加密)尚未有效迁移到教育个性化学习中,以解决低资源场景下的隐私-轻量化张力。
involved_units:U9

【对照分析】

迁移类是五类空白中唯一允许引入"综述之外的知识"的类型:执行本步的大模型,自身知识中已包含"医疗等领域存在轻量化隐私方案"这类综述里没有的信息。但证据要求不变——问题本身(U9 记录的延迟与开销)必须出自真实的单元卡,综述之外的知识只能用来说明"这个问题在其他领域已有解决办法",不能用来虚构问题。(G3 后来成为研究目标三。)

四、总表:本轮挖出的三条空白及去向

id	类型	涉及单元	一句话	后来去向
G1	能力缺口	U2,U6,U8,U9	没人同时做到轻量+公平+隐私	研究目标一,锦标赛第 1,选定
G2	数据场景缺口	U3,U5	只在高资源数据上验证过	研究目标二(反思标记口)
G3	迁移缺口	U9	别处的轻量隐私技术没人搬到教育来	研究目标三

三条空白类型互不重复(提示词中"类型需多样"的要求生效);每条均可追溯——沿 involved_units 可以查回具体的卡、具体的局限,直至综述原文的具体一行。

教育案例全链路实录·去重 + C 步:空白去重,再转成候选目标

本站(即管线的本阶段)包含两个环节:去重与 C 步。上一步 B 步一次会提出多条研究空白,彼此可能只是同一空白的不同说法,去重环节负责合并这类语义重复;C 步再把空白改写成候选研究目标,行文须达到可直接放进项目申报书的水准。上一站三条空白的简称沿用:G1(轻量/公平/隐私无人兼顾)、G2(低资源场景未验证)、G3(隐私技术未迁移)。

一、第一环节:去重(step_dedup → gaps_merged.json)

【职责】

LLM 只做一件语义判断:哪几条空白是"同一个底层空白的不同说法"。判断完成后分组,并为合并组撰写综合 summary;其余工作全部由代码完成——按每组的 merged_from 字段(记录该组由哪几条原空白合并而来)取证据单元的并集、重新编号 G1..Gn。(分工原则:语义判断交给模型,取并集、重编号这类机械整理工作交给代码,二者不越界。)

【本轮实况】

三条空白分属不同类型——G1 是能力缺口、G2 是数据场景缺口、G3 是迁移缺口,LLM 判定无重复,gaps_merged.json 与输入一致,仍为三条。本轮去重环节没有触发合并动作。

【无动作轮次的可信度:负对照验证】

专门的 test_dedup 实验:人工构造三条测试用空白(测试数据自带编号,与正文的 G1~G3 无关)——其中第一条与第三条是同一个空白("非随机缺失假设失效")的两种措辞、各附不同证据,第二条独立。验证三件事全部通过:三条合并为两条;合并组证据等于两条的并集(证据不丢失);独立的那条未被误合。

要点:去重这类质量检查环节的价值在于"真出现重复时能可靠拦下",而不在于"每轮都有合并动作"——本轮无动作,是因为上游产出本轮不含重复,而非机制失效。

二、第二环节:C 步(step_c → candidates.json)

【职责】

把每条空白转写为一个候选研究目标,含五个字段:objective(目标句)、key_problems(拟解决的关键问题)、quantitative_delta(定量增量:指标/现状值/目标值/增量)、evidence_from_review(证据单元指针)、why_not_trivial(为何不平凡)。

防幻觉纪律:现状值只准引用单元卡中真实存在的数字并注明出处;没有基线则如实写"需补充调研";目标值一律标注"拟定/预期";指标必须写清计算口径(比例要写明分母、阈值要有可操作的测量定义);声称的适用范围不得超出证据支持的范围。

【对照例:G1 → 候选一(照录 candidates.json 关键字段)】

objective:开发一个轻量化AI框架,在低资源教育设备(如农村学校常见设备)

上实现部署,计算需求降低50%,公平性差异比例减少40%,

隐私保护延迟控制在100ms以内。

key_problems:

1. U2和U6的计算复杂性(需GPU集群)导致无法在83%中国农村学校等

低资源环境部署,违反轻量化要求。

2. U8和U2的算法偏见放大人口统计差异(如风险预测偏见比例达2.3倍),

损害公平性保障。

3. U9的隐私技术(如联邦学习)在低带宽网络延迟飙升,与轻量化部署冲突,且无单元整合三者。

quantitative_delta:

metric = 风险预测偏见比例

current_level = 2.3倍 (U8 limitation) ← 现状值自带出处

target_level = 预期≤1.5倍 ← 目标值挂"预期"标签

increment = 从2.3倍降低到≤1.5倍

evidence_from_review:[U2, U6, U8, U9]

【转写过程解析】

- 空白的"没有人同时做到"转为 objective 的"本项目拟同时做到"——空白陈述问题,候选给出承诺。
- 空白条目里描述矛盾的 tension 字段(一段文字)被拆写成 key_problems 的三条,每条标注 U 编号,可逐条追溯到对应的单元卡核对。
- 定量增量是全部字段中约束最严的:现状值 2.3 倍必须标注"(U8 limitation)",目标值 ≤1.5 必须标注"预期"——真实数字必须注明出处,拟定数字必须明确标注它是拟定或预期值。
- evidence_from_review 的四个 U 编号会传给后续 design 站:该站设定研究对象与基线时,只允许引用这四张单元卡,不得另找证据。

【第二个对照(简述):G2 的定量增量存在隐患】

G2 候选的 current_level 写入了"87%". 该数字真实存在于 U3 的指标中,但其原义是"整体基准测试准确率",在此被挪用为"低资源语言环境的现状基线"——数字为真,语义被偷换。C 步未能拦截,该隐患留给下一站(反思)处理;这也正是"C 步之后必须设反思站"的最好证明。

三、总表:本站进出

进:3 条空白(G1/G2/G3) → 去重:无合并,原样 3 条 → C:3 个候选目标

候选	源空白	目标一句话	定量增量	证据指针
一	G1	低资源设备上轻量+公平+隐私的AI框架	偏见比例 2.3倍 →预期≤1.5(U8溯源)	U2,U6,U8,U9
二	G2	低资源/多语言/稀疏场景的评估与优化	87%...(语义有偏,待反思裁决)	U3,U5
三	G3	把别处的轻量隐私技术迁移到教育	延迟3.7倍→拟定控制(U9溯源)	U9

教育案例全链路实录·反思站:四项打分,拦截 C 步遗留的语义隐患

反思站逐条审查上一环节 C 步产出的每个候选目标,由担任评审的 LLM 按四项标准各打 1~3 分:
① 无幻觉与数值语义正确;② 具体可证伪;③ 与空白对齐一致;④ 证据对应。判决分三档:任一项 1 分即淘汰(硬伤,不再进入后续步骤);出现 2 分即标记(可疑,带 □ 继续进入后续步骤、交人工确认);全部 3 分为通过。本站属判别类任务,模型采样温度设为 0.2,以降低随机性、让打分更稳。只有通过与标记的候选能进入下一环节 D 步(扩写成申报书正文)。本篇沿用源空白编号指代各候选:G1(轻量/公平/隐私无人兼顾)、G2(低资源场景未验证)、G3(隐私技术未迁移)。

一、对照例一:G2 的语义偏移被拦截(照录 reflections.json)

【判决记录原文】

```
gap_id: G2
scores: 无幻觉=2, 具体可证伪=3, 对齐一致=3, 证据对应=3
无幻觉项理由:"current_level 87% 来自 U3 的整体准确率指标,
    但被用于低资源语言环境基线,而 U3 未提供该场景具体数值,语义偏移。"
verdict:标记
总评:"整体对齐 gap 且证据相关,但 quantitative_delta 基线数值
    语义有偏,需审查。"
```

【解析】

C 步遗留的隐患在此被精确定位:评审(即打分的 LLM)并未认定"87% 是假的"(该数字为真),而是指出"数字真、语义偏"——整体准确率被挪用为特定场景的基线。这正是四项标准中"无幻觉与数值语义正确"一项的设计意义:它不仅检查数字是否存在,还检查数字的含义是否被偷换。

判"标记"而非"淘汰"同样值得注意:问题出在单个字段的语义,目标整体仍然成立。三档判决的中间档正是为此类情况设计:既避免因局部瑕疵否定整个方向,也不放过问题——□ 标记会随候选一路传递:G2 对应的成稿目标(research_goal.txt 中的目标二)标题带"□ 待人工确认",后续负责拼装申报书 PDF 的 make_plans 程序在输出中同样保留该标注,直到有人处理为止。

二、对照例二:G3 四项全 3 分的理由原文——评分标准确实在执行

【判决记录原文(无幻觉项理由)】

```
"数值3.7倍在U9的limitation中可溯源,且作为隐私保护延迟增长倍数的
    现状水平语义正确,未混淆为降幅或其他指标。"
```

【解析】

"未混淆为降幅"一语表明,评审在主动排查一个特定的历史事故模式。事故来历:2026-07-16 第一次把整条管线端到端连通运行时,模型曾把综述中的"降幅 32%"写成"基线 32%"——数字本身没变,但它代表的含义变了(从"降幅"变成了"基线")。该教训固化为两层防御:

- LLM 层:无幻觉标准强化——评审必须判断 current_level 究竟是"现状水平"还是"降幅或其他指标",无法判定时该项最多给 2 分;
- 代码层 tripwire(_num_semantics_flag):current_level 字段中出现"降低/提升/reduction/mitigation"等表示变化方向的词语时,无论评审给出什么结论,该候选的最终判决都不会好于"标记"。

G3 的这句理由,即 LLM 层防御逐条执行的直接证据。

三、对照例三:G1 全票通过(简述)

四项全部 3 分。无幻觉项理由:"数值2.3倍在U8单元的limitation中可溯源,且语义正确作为现状水平"。G1 就此成为三个候选中最干净的一个,也为其后来在锦标赛中位列第一奠定了基础。

四、这套打分为何可信:负对照验证(test_reflect)

实验设计:人工构造 1 条干净候选,另构造 4 条各埋入一种已知缺陷——编造基线(凭空写 RMSE=0.15)、空话目标(只有泛泛表态、无具体可证伪内容)、挂错证据(引用无关单元)、关键问题与空白不一致。

结论(如实记录,含局限):

- 编造基线、挂错证据两类:稳定淘汰,且对应评分项精确打 1 分;
- 干净候选:不误杀;
- 空话、不一致两类:识别受模型随机性影响,时而抓住时而遗漏——因此本机制从一开始就只声称对前两类具备稳定拦截能力,不夸大覆盖面。

要点:负对照的价值不仅在于"证明机制有效",更在于精确划出"机制无效的边界"。

五、总表:本轮判决

候选	四项得分	判决	后果
G1	3/3/3/3	通过	干净进入 D 步(后来的目标一)
G2	2/3/3/3	标记	带 □ 进入 D 步,成稿与 PDF 持续标注
G3	3/3/3/3	通过	进入 D 步(后来的目标三)

进:3 个候选 → 出:3 个(淘汰 0 条、标记 1 条)。存 reflections.json。

教育案例全链路实录·成稿三环节:D 扩写 → 锦标赛 → 人工选定

研究目标生成工具 goal_gen 的最后三个环节:把经反思筛选后保留的候选扩写为申报书正文(流程编号 D 步),对完整正文打分排序(锦标赛),由人选定唯一目标(选定)。扩写与打分均由大模型执行,采样温度分别为 0.4 与 0.2。

一、第一环节:D 扩写(step_d → research_goal.txt)

【职责】

把每个候选(结构化 JSON)扩写为一段连贯的申报书正文,每条独立成文、不合并。硬性禁令:U 编号不得出现(读者不应看到内部编号);无依据的最高级表述("首个/率先/最优")不得出现;未定义的数学符号(如谱半径)不得出现;不得有开场白——提示词明令禁止,另有正则表达式作第二道保险,自动删除"以下是/Here is"一类语句。反思站打出的 □ 标记会一并写入对应目标的标题:"研究目标二 □ 待人工确认"。

【对照:候选一的 key_problems(内部版) → 目标一正文(读者版)】

内部版(candidates.json,带单元编号):

"U2和U6的计算复杂性(需GPU集群)导致无法在83%中国农村学校等低资源环境部署..."

"U8和U2的算法偏见放大人口统计差异(如风险预测偏见比例达2.3倍)..."

"U9的隐私技术(如联邦学习)在低带宽网络延迟飙升..."

读者版(research_goal.txt 目标一,照录节选):

"现有机器学习方法和强化学习的高计算复杂性(需要GPU集群支持)导致无法在83%中国农村学校等低资源环境部署,违反轻量化要求;

AI辅助评估工具和机器学习方法的算法偏见放大人口统计差异,

如风险预测偏见比例达2.3倍,损害公平性保障;

隐私增强技术在低带宽网络下延迟飙升,与轻量化部署冲突...

目标是通过创新设计,将计算需求降低50%,公平性差异比例减少40%

(具体体现为风险预测偏见比例从2.3倍降低到预期≤1.5倍),

并将隐私保护延迟控制在100ms以内..."

【解析】

- U2 和 U6 译为"现有机器学习方法和强化学习",U8 译为"AI辅助评估工具",U9 译为"隐私增强技术"——内部编号逐一转换为方法名称,编号体系对读者完全不可见,但每句话仍能追溯回它所依据的那张单元卡。
- 83%、2.3 倍等真实数字原样保留;50%、40%、100ms 为拟定目标(2.3→≤1.5 一句仍带"预期"标注)。
- 成稿按"研究目标一/二/三"拼装,目标二标题带 □——反思站的结论以可见方式呈现在读者面前。

二、第二环节:锦标赛(step_tourney → tournament.json)

【职责】

由模型对"扩写后的完整目标正文"按三个维度打分:依据强度、研究价值、可行性,各 1~5 分,按总分排名。只输出排名与理由,不改变成稿顺序。

【本轮排名】

名次	目标	总分	三维	理由要点
1	一	14	5 / 5 / 4	四个证据单元直接支撑
2	二	11		(带 □,基线语义待确认)
3	三	9		单一证据单元,依据面窄

【三个设计决策】

- 为何安排在 D 步之后、对完整正文打分:申报书未来的评审专家读到的将是正文,而不是内部的结构化底稿(JSON 候选),打分对象应当与读者所见是同一份文本。
- 为何只排名、不重排成稿:成稿中目标的排列保持生成顺序,因为随后的人工选定靠编号定位目标,按名次重排会使编号错位;排名只是给人的参考信息,不是裁决。
- 已知偏差(如实记录):依据强度这一维度天然有利于支撑单元卡多的目标——目标三(源自空白 G3,隐私技术迁移方向)仅有一张单元卡支撑,因而排名垫底。证据覆盖面广的方向往往也是较成熟的方向,因此新颖但证据少的方向会处于劣势;若需矫正,可增设"新颖性"维度(已记录在案的备选改进)。

三、第三环节:人工选定(step_pick → selected_goal.json)

终端列出全部目标(附 □ 标记与锦标赛名次),由人输入编号选定唯一目标。本轮选定 1,落盘 selected_goal.json:{"index": 1}——这份十八个字节的文件是下游 design 站开始运行的前提:缺少它时,design 站直接退出,不猜测选了哪个目标。

兜底设计有三处:其一,直接回车或在非交互环境运行,等同于不选、保留全部目标,此时负责拼装申报书 PDF 的 make_plans 程序会为三个目标各出一份方案(plan1~3);其二,make_plans 中另设一次补选机会——此前实际发生过把多行命令整块粘贴进终端、多余的行被选定提示当作输入读走的误操作,补选用于弥补这类情况;其三,程序捕获了 EOFError——后台管道环境中 isatty 可能把非交互环境误判为交互终端,读取输入时会抛出该异常。

机器给出排名,但选择权在人——锦标赛判定目标一最强,仍需人工亲手输入 1 确认选定。

四、总表:goal_gen 全程收官

9 张单元卡 → 3 条空白 → 去重后仍 3 → 3 个候选 → 反思(淘汰 0 条、标记 1 条) → 扩写成 3 段正文 → 锦标赛 14/11/9 → 人工选定目标一。

产物:research_goal.txt / tournament.json / selected_goal.json

教育案例全链路实录 · design 站(上):①认定领域

②定死钉子并分类维度

design 站(管线中设计实验方案的阶段)开工之前先做两件确立规则的事,两件事都会停下等待人工确认(即"黄灯":程序暂停,把关键决定打印在终端,人确认或改掉后才继续)。

第一件,认定课题所属领域(领域画像)。其来历是一次真实事故:为硬件课题生成方案时,文中出现了"CPU 容器限带宽"这类计算机课题的话术——原因是提示词中写死的示范例子带有上一个领域的印记(示例锚定)。解决办法不是把每个领域的词汇表写进代码——枚举无法穷尽。改为只给模型一条统一的判断标准:"该说法在该领域的论文中是否自然出现"。模型据此针对眼前课题现场推导应使用的表述与验证手段,推导结果再交人工过目。

第二件,定死三颗钉子,并对研究目标包含的每个技术维度(本课题为轻量化、公平性、隐私保护)分类。钉子即锁死的控制变量:研究什么任务、以哪个载体(实验所依托的基础模型或系统)为实验对象、用什么数据——若不钉死,LLM 撰写长文时会发生漂移,写到后面各节自行更换数据与模型,比较即告无效。分类三问决定实验设计的形状:每个维度是可以开关的"干预",还是只能选取值的"条件因素",还是仅关乎"怎么测"的测量协议?无法判定则如实归入"待人工"。

这两步必须人工确认,有实证依据:一次跳过人工确认、由程序自动采纳模型全部提议的运行中,基准载体被证据卡里一组高显著性的 GBM(梯度提升机)指标带偏,此后整份方案围绕错误载体越写越自治——此类偏离只有黄灯环节的人工审视能够拦截(详见第二节)。

一、第①步:领域画像(step_domain → design_domain.json)

【职责】

输入:选定目标正文、被其引用的四张证据卡(即该目标引用的那四张方法单元卡)、研究需求。模型识别课题领域,产出一份"领域画像",经人工确认后全程遵循。统一判断标准只有一条:该说法/做法在该领域的论文中是否自然出现。

【教育课题的画像(照录 design_domain.json 要点)】

领域判断:教育人工智能领域的轻量化系统设计课题,以 AI 系统优化为主

(依据:目标正文明确提及低资源教育场景与轻量化 AI 框架,

引用单元在 Kaggle 教育数据集上验证)

验证手段(节选):

- 在标准教育数据集上做 k-fold 交叉验证,测准确率/公平差异/计算开销
- 在模拟低资源硬件环境中测推理延迟与资源消耗
- 用公平性审计框架评估不同人口统计群体的偏见程度

自然用语(节选):个性化学习框架、低资源部署、公平性差异比例、教育数据集

外行词替换:[] (空)

兼容约束(节选):轻量化维度——优化手段需适配无 GPU 的低端硬件

替代验证:云平台配置受限硬件资源模拟低资源环境 + 公开教育数据集测试

【空数组的来历】

画像初版的"外行词替换"栏规定"至多 8 条",模型倾向把名额填满,于是凑出了伪禁词("模型→框架" "训练→算法优化"——这些在 AI 论文中本是自然用语);下游的 LLM 评审把这份替换表当作禁词表逐条执行,将全篇"基准模型"误改为"基准框架"。修正方案:为该栏加入"宁缺毋滥——没有真正的外行词就交空数组"的规则。上面的 [] 即该规则生效的证据:教育课题本属 AI 领域,没有外行词可禁,交空才是

正确答案。(同一套画像机制在电力除冰课题上则自动给出台架/仿真类验证手段,且无计算机词汇混入——通用性由第二领域验证。)

二、第②步:钉子与维度分类(step_pins → design_pins.json)

【职责】

单次模型调用完成三件事,随后触发黄灯、程序暂停等待确认:

- 提议三颗钉子——核心任务、基准载体、主数据。硬规则:主数据只能取自被引用卡的 data_scene 字段(该字段记录各方法原论文所用的数据与场景;卡中没有则写"待调研确定",严禁编造数据集名称);所选载体必须能同时实现每个技术维度对应的机制。
- 对每个技术维度做分类三问,按第一个通过的测试定型:测试1【干预】——能否在同一载体上做出"带它/不带它"两个版本对照?测试2【条件因素】——它是否为对象/环境自带的属性,只能选取值?测试3【测量协议】——它改变的是否仅是"怎么测"?三问皆不通过则归入"待人工",不强行归类。每条附判断依据(evidence)。
- 全局判断:目标是否含长期性/可靠性要求(决定是否需要寿命试验)。

【教育课题的真实输出(照录终端/design_pins.json)】

维度1 [干预] 轻量化——通过测试1:可以设计带/不带轻量化机制的框架
版本对照,依据目标正文"将计算需求降低50%"的要求
维度2 [干预] 公平性——通过测试1(带/不带公平机制可对照)
维度3 [干预] 隐私保护——通过测试1(带/不带隐私机制可对照)
长期性要求:无
推出模式:统一框架(由分类真值表机械推出)
实验骨架:块1 因子对照试验——三因子全部开/关两水平 → 列全 2^k 配置
钉子提议:
核心任务 = 低资源教育设备上兼顾轻量化/公平/隐私的个性化学习方法
基准载体 = 基于神经网络的个性化学习模型
主数据 = Kaggle 的"AI 驱动的个性化学习数据集"(2025)
确认界面:回车=全部接受;u/l=改结构;c=逐条改维度分类

【黄灯不可省略的实证:一次真实的钉子漂移】

一次非交互(自动采纳)的运行中,证据卡里 Junaidi 研究的 GBM 指标($R^2=0.9997$)显著性突出,导致模型把基准载体错误地提议为 GBM。这违反项目内部约束(量化/剪枝/蒸馏类轻量化手段要求神经网络载体),但"GBM 剪枝"这种做法在公开文献中确实存在、并非编造,因此 LLM 评审查不出"违反了项目自身的约束";错误钉子进入后,下游还围绕它生成了一条表面专业连贯的技术链(特征重要性剪枝→改分裂准则→Scikit-learn)。此类"越编越自治"的错误,只有黄灯环节的人工审视能够拦截——终端上并排打印着"基准载体=GBM"与维度分类,"载体是 GBM、而轻量化机制要求神经网络载体"的矛盾任何人三秒内即可发现,在确认界面键入正确载体即可纠正。该份稿件已归档,标注"结构合格、钉子失败",留作证明黄灯环节必要性的实例。

三、总表:两步的产物

产物文件	内容	人工动作
design_domain.json	领域/验证手段/用语表/兼容约束	确认或改领域
design_pins.json	三颗钉子+维度分类+长期性+实验骨架	确认或c逐条改

两步各调用一次模型(均为小规模调用)、各暂停一次等人确认。自此,"说什么话"(领域画像)与"在什么上做实验"(钉子)全部定死,后续环节——分解出底稿、扩写成文、自动评审——都必须遵守这两份已确认的文件,不得越出其规定。

教育案例全链路实录 · design 站(下):③推实验骨架 ④扩写四节

⑤评审与安检

第③步是全流程中最特殊的一步:决定"实验长什么形状"的不是模型,而是几行代码查一张真值表。最关键的结构决定反而不使用 AI,原因在于:分类完成之后,"从分类到结构"是查表而非判断,以 LLM 执行查表,只会为确定性工作引入不必要的随机性。纯代码的优势:同输入必同输出、可单元测试、出错可归因,且不存在"模型照搬提示词示例"的风险——纯代码没有提示词,无从被示例带偏。

第④步把底稿扩写为四节文字,核心是各节各守其位的分工:(一)研究内容只回答"研究什么",无需特殊规则;(二)是实验操作说明书——怎么分组、测什么、怎么分析;(三)是技术选型说明书——为什么选它而非别的,只写机制自带的内在特性,不写"能降多少"这类须经实验才知道的承诺;(四)是"为什么做得成"的论证——成熟度、工具、条件都归于此。

第⑤步设两道关:LLM 评审按 11 条标准查找问题(本轮确实查出"正文写七组、配置表八组"的计数错误),随后执行"出稿安检"——代码对成稿做四道正则一致性检查("安检"取"出稿前最后一道检查"之意,与信息安全无关)。安检遵循的原则是"宁可误报、不可漏报":把不能确定的问题全部列出,裁决权始终在人。

一、第③步:代码推实验骨架 + 分解出底稿(design_items.json)

【真值表(写死在代码里,不经模型)】

干预数	条件因素数	长期性	推出的实验结构
≥2	0	无	单块因子对照试验(= 2 ^k 消融)
≥2	0	有	因子对照块 + 寿命试验块
≥1	≥1	无	对照块 + 多水平因素块(含交互)
≥1	≥1	有	对照块 + 多水平块 + 寿命块
0	≥1	—	多水平因素试验(观察性比较)
0	0	—	设计待人工
任一维度"待人工"	设计待人工		

【教育课题所走的行】

上一步分类结果:3 个干预、0 个条件因素、无长期性要求 → 命中第一行 → 单块因子对照试验,三因子全开/关 → 2³ = 8 种配置。

【分解底稿要点(照录 design_items.json)】

基线指标(只列名、不填数——数值是立项后实验测出来的):
准确率 / AUC / CPU推理延迟(毫秒,在模拟低资源设备如 Raspberry Pi 4 单核 1.5GHz、批量为 1 的条件下) / 模型大小(MB) /
风险预测偏见比例(定义为弱势群体高风险预测比例与优势群体之比) /
Equal Opportunity Difference / 各群体假阳性率
三个机制层(每层 2~3 条备选,优点缺点都必须写):
轻量化:INT8量化(选定) vs 模型剪枝 vs 知识蒸馏
公平性:对抗性去偏(选定) vs 重加权 vs 阈值后处理

隐私:差分隐私(选定) vs 同态加密 vs 联邦学习
相互作用假设(2 组,各配度量):
轻量化×公平:压缩可能放大数据稀少群体(农村学生)的预测偏差
公平×隐私:隐私噪声可能扰动公平约束
八组配置(C0~C7,带优先级):
基准 / 三个单开 / 三个两两组合 / 全开;
标注"主实验 / 补充消融"两档

【底稿要点解析】

- 基线指标中,延迟指标附有测量条件、自造指标附有定义——这是既定规则的结果:凡写阈值必须注明测量口径,凡写比例必须写清分母与定义。
- 机制层中,选定路线自身的代价也如实列明(INT8 量化"可能引入量化误差");联邦学习的弱点栏写明"需另配隐私机制",以免把它误当作独立的隐私保护方案。
- 八组配置一组都不能省:资源有限时,只允许按"主实验/补充消融"区分优先级,不允许删掉任何一组——缺任何一组,对应的交互效应即无法估计。

二、第④步:扩写四节(step_write → design.txt 正文)

【节间分工表(写入提示词的硬规则)】

节	只回答	不许碰
(一)研究内容	研究什么	——
(二)思路方法	怎么做、目标定在哪	——
(三)比较优势	凭什么选它不选别的	数值承诺、可行性、总结升华句
(四)可行性	凭什么做得成	重复技术比较

【成稿中的执行实例(照录 design.txt)】

统一性宣言(必须写出):"所有机制作用于同一个基准模型、同一套主数据,确保实验统一性。"
(二)的分析语言(全因子而非"做减法"):"通过方差分解估计各因子的主效应、两两交互效应(轻量化×公平性、轻量化×隐私保护、公平性×隐私保护)及联合效应"通过重复实验获取均值、标准差及 95% 置信区间"。
(三)的选型语言(内在特性,不是效果承诺):"选定权重剪枝因其结构化稀疏特性更适配.....""差分隐私能提供形式化隐私保证"——写的是机制原理直接成立的性质;"能降低多少延迟"这类要实验才知道的话不许出现。

三、第⑤步:评审修订 + 出稿安检 + 复核清单

【LLM 评审:11 条标准按试验块逐项检查(本轮查出 4 条,照录 design_review.json)】

[标准6d] 隐私延迟指标在基准配置(未引入隐私机制)下不可测量
→ 改为"机制引入后相对基线的额外开销"
[标准6b] 绝对阈值未注明测量条件、未绑定效用下限
[标准11] 实验设计声称七组,但全因子应有八组(2^3),正文计数错误
→ 按 configs 表改回八组
[标准6e] 目标值口径不一致(一处相对表述、一处绝对值)

其中标准 11(按试验块清点配置组数)是本轮新增的检查,首次运行就查出了问题:正文与配置表不一致,当场点名。修订纪律:只修被点名之处,不新增事实与数字,最多两轮。

【纯代码安检(四道正则检查:不花模型调用费用,同输入必同输出)】

- U 编号残留检查:若成稿正文仍出现内部 U 编号,程序再执行一轮专项清除改写;无法对应的编号替换为"现有相关方法"。
- 数字溯源:正文中的数字要么可在源材料中找到,要么其邻近有"拟/预期/待"等字样。
- 借用基线检查:证据卡(目标引用的方法单元卡)中的文献数字出现在"基线/降至"语境时给出警示——防止把文献里的数字直接当成本项目的基线或预期结果。
- 交互覆盖检查:声称的每组相互作用,必须有对应试验块能够估计。

【已知误报,如实交由人工(复核清单的定位)】

数字检查曾把 AIF360 工具名中的"360"当作来源不明的数字列入清单——机器无法区分"事实数值"与"软件名称中的数字",但它不做裁决、只做上报。复核清单同时列明:哪些判断是在无人确认的情况下被自动采纳的、申报书"条件可行"部分还缺哪些支撑材料、评审还遗留了哪些问题——逐条处理完毕并删除清单,方为交付。

四、总表:design 站全程收官

前序环节选定的研究目标一 + 其四张证据卡 → ①画像(定下该领域的话术) → ②钉子+分类(定下实验的基本形状) → ③真值表推出单块 2^3 、分解出底稿 → ④扩写四节(各守其位) → ⑤评审 4 条修订 + 四道安检 → design.txt + 人工复核清单。

产物:design_domain / design_pins / design_items / design_review.json + design.txt